PERTH HOUSE PRICING

Alex Rodrigues de Oliveira

Leila Fabiola Ferreira

Mercado Imobiliário

Apresentou maior crescimento de lançamentos dos últimos 10 anos - Câmara Brasileira da Indústria da Construção (CBIC)

Crescimento de 12% no Brasil, em relação ao ano anterior - Associação de Dirigentes de Empresas do Mercado Imobiliário (Ademi)

O Valor Geral de Vendas (VGV) tem previsão de encerrar o ano em R$ 99 bilhões - Associação de Dirigentes de Empresas do Mercado Imobiliário (Ademi)

Os preços dos imóveis australianos devem apresentar um pico de 10% no próximo ano - Commonwealth Bank

Objetivos Centrais

Utilizar diferentes métodos de *ensemble* das *Machine Learnings* para melhorar as predições já existente sobre o preço dos imóveis (*House Pricing*).

Comparar os métodos através das métricas de coeficiente de determinação (R^2) e erro médio quadrático (MSE) procurando obter os melhores resultados para os mesmos.

Fazer uma aplicação (*deploy*) simples para os modelos treinados.

Sumário

ETL (GitHub)

Dataset original - Perth House Prices (Kaggle)

	ADDRESS	SUBURB	PRICE	BEDROOMS	BATHROOMS	GARAGE	LAND_AREA	FLOOR_AREA	BUILD_YEAR	CBD_DIST	NEAREST_STN	NEAREST_STN_DIST	DATE_SOLD	POSTCODE	LATITUDE	LONGITUDE	NEAREST_SCH	NEAREST_SCH_DIST	NEAREST_SCH_RANK
0	1 Acorn Place	South Lake	565000	4	2	2.0	600	160	2003.0	18300	Cockburn Central Station	1800	09-2018\r	6164	-32.115900	115.842450	LAKELAND SENIOR HIGH SCHOOL	0.828339	NaN
1	1 Addis Way	Wandi	365000	3	2	2.0	351	139	2013.0	26900	Kwinana Station	4900	02-2019\r	6167	-32.193470	115.859553	ATWELL COLLEGE	5.524324	129.0
2	1 Ainsley Court	Camillo	287000	3	1	1.0	719	86	1979.0	22600	Challis Station	1900	06-2015\r	6111	-32.120578	115.993579	KELMSCOTT SENIOR HIGH SCHOOL	1.649178	113.0
3	1 Albert Street	Bellevue	255000	2	1	2.0	651	59	1953.0	17900	Midland Station	3600	07-2018\r	6056	-31.900547	116.038009	SWAN VIEW SENIOR HIGH SCHOOL	1.571401	NaN
4	1 Aman Place	Lockridge	325000	4	1	2.0	466	131	1998.0	11200	Bassendean Station	2000	11-2016\r	6054	-31.885790	115.947780	KIARA COLLEGE	1.514922	NaN

Transformações aplicadas

```
df['BUILD_YEAR'] = pd.to_datetime(df['BUILD_YEAR'], format='%Y')
df['BUILD_YEAR'] = pd.to_datetime(df['BUILD_YEAR']).dt.strftime('%Y')
df['DATE_SOLD'] = df['DATE_SOLD'].map(lambda x: x.rstrip('\r'))
df['MONTH_SOLD'] = pd.to_datetime(df.DATE_SOLD).dt.strftime('%m')
df['YEAR_SOLD'] = pd.to_datetime(df.DATE_SOLD).dt.strftime('%Y')
df.drop('DATE_SOLD', axis='columns', inplace=True)
df = df[df['BATHROOMS']<15]
df = df[df['GARAGE']<=10]
df = df[df['FLOOR_AREA']>=50]
df = df[df['LAND_AREA']<=900000]
```

ETL (GitHub)

Dataset transformado – ETL finalizado

	ADDRESS	SUBURB	PRICE	BEDROOMS	BATHROOMS	GARAGE	LAND_AREA	FLOOR_AREA	BUILD_YEAR	CBD_DIST	NEAREST_STN	NEAREST_STN_DIST	POSTCODE	LATITUDE	LONGITUDE	NEAREST_SCH	NEAREST_SCH_DIST	NEAREST_SCH_RANK	MONTH_SOLD	YEAR_SOLD
0	1 Addis Way	Wandi	365000	3	2	2.0	351	139	2013	26900	Kwinana Station	4900	6167	-32.193470	115.859553	ATWELL COLLEGE	5.524324	129.0	02	2019
1	1 Ainsley Court	Camillo	287000	3	1	1.0	719	86	1979	22600	Challis Station	1900	6111	-32.120578	115.993579	KELMSCOTT SENIOR HIGH SCHOOL	1.649178	113.0	06	2015
2	1 Arundel Street	Bayswater	685000	3	2	8.0	552	126	1999	5900	Bayswater Station	508	6053	-31.917880	115.907050	CHISHOLM CATHOLIC COLLEGE	0.936243	29.0	10	2019
3	1 Ashcott Gate	Butler	367500	3	2	2.0	398	158	2003	36300	Butler Station	2100	6036	-31.654280	115.702200	BUTLER COLLEGE	0.680843	39.0	11	2018
4	1 Ashendon Boulevard	Hammond Park	535000	4	2	4.0	704	247	2002	23100	Cockburn Central Station	3900	6164	-32.159590	115.849480	ATWELL COLLEGE	2.220643	129.0	07	2019

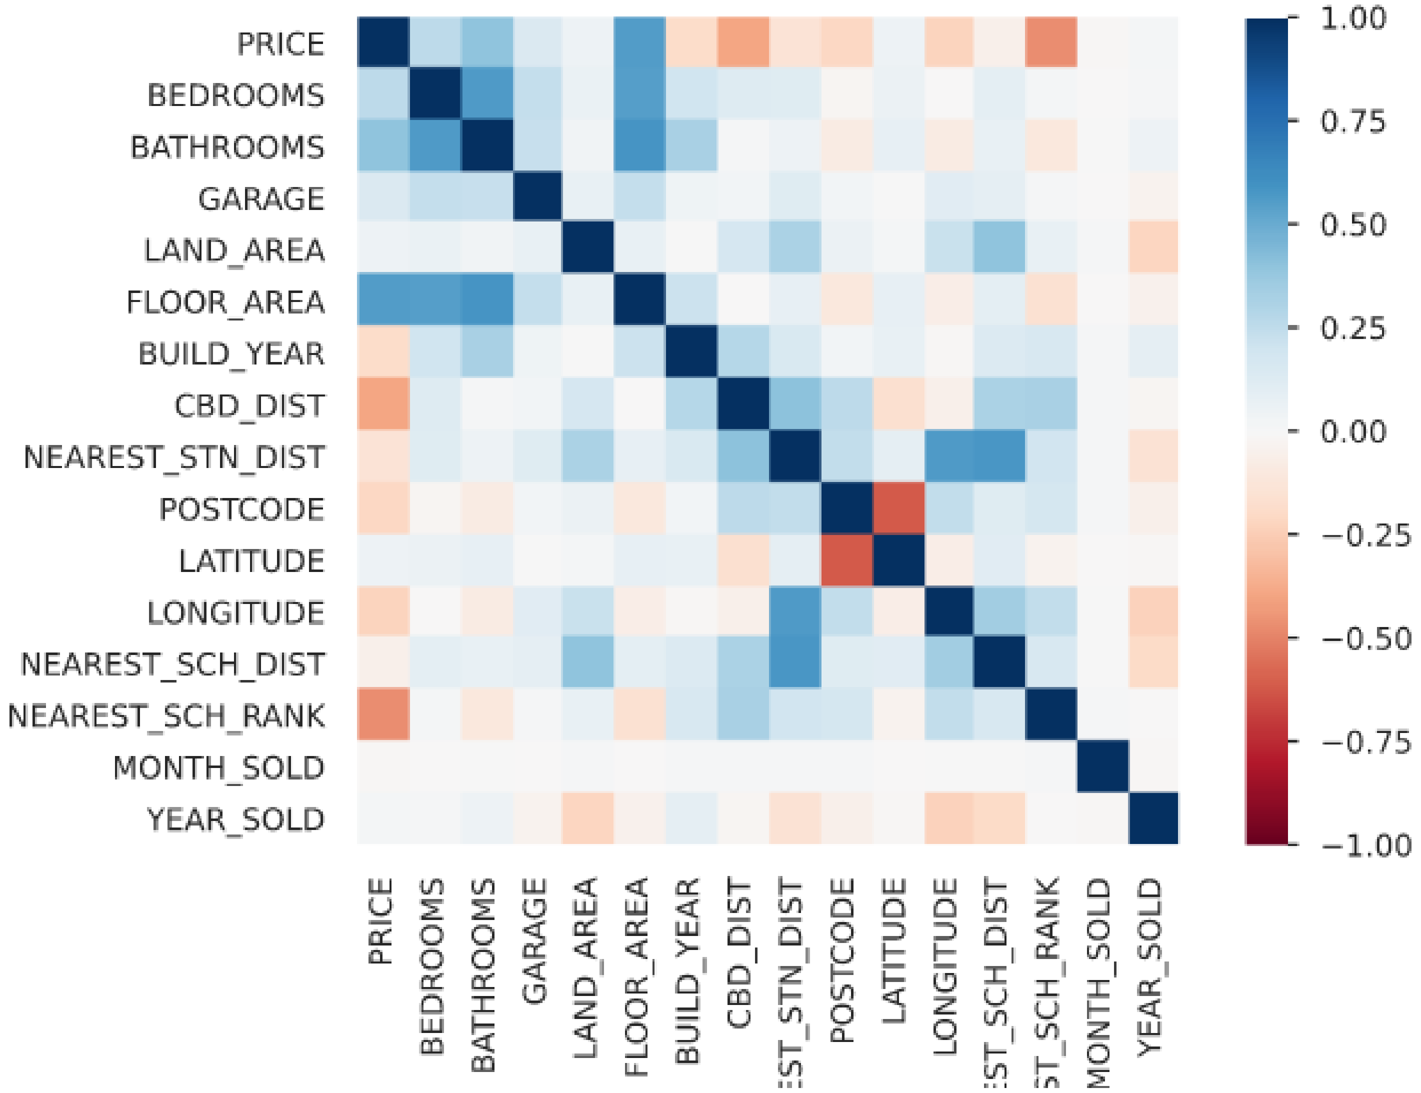

EDA (GitHub)

Correlação de Pearson

FLOOR_AREA e BATHROOMS apresentam as maiores correlações positivas.

NEAREST_SCH_RANK e CBD_DIST apresentam as maiores correlações negativas.

LAND_AREA e MONTH_SOLD parece não apresentar correlação.

EDA (GitHub)

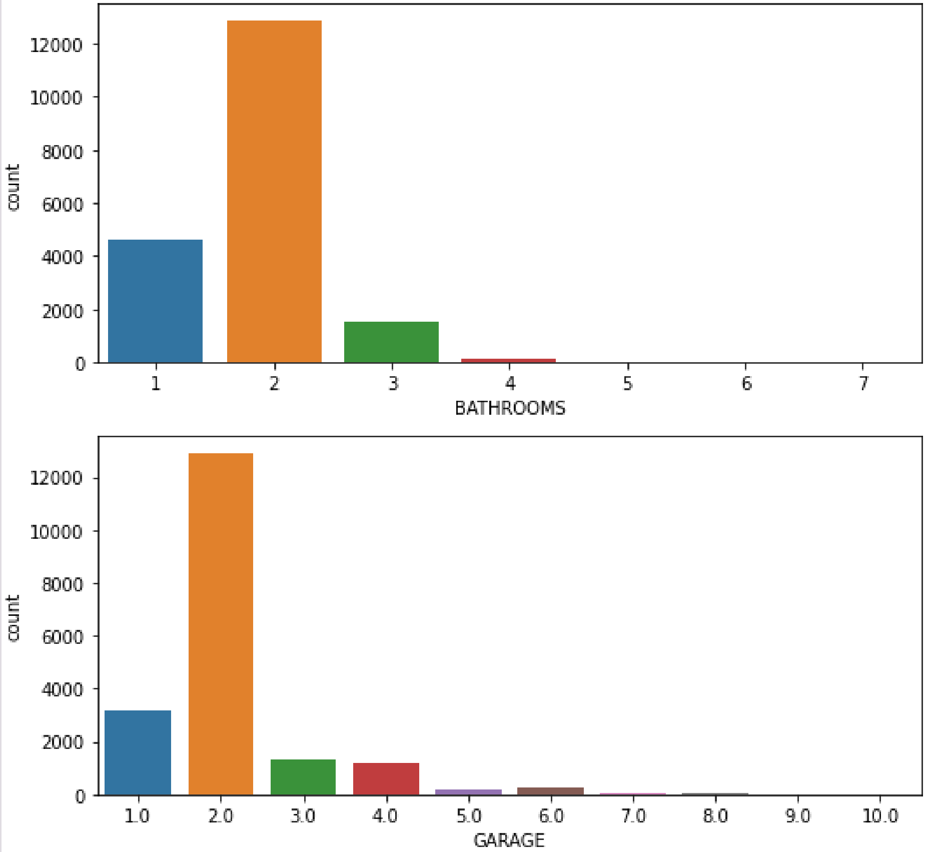

Banheiros, Quartos e Vagas de Garagem

Preço

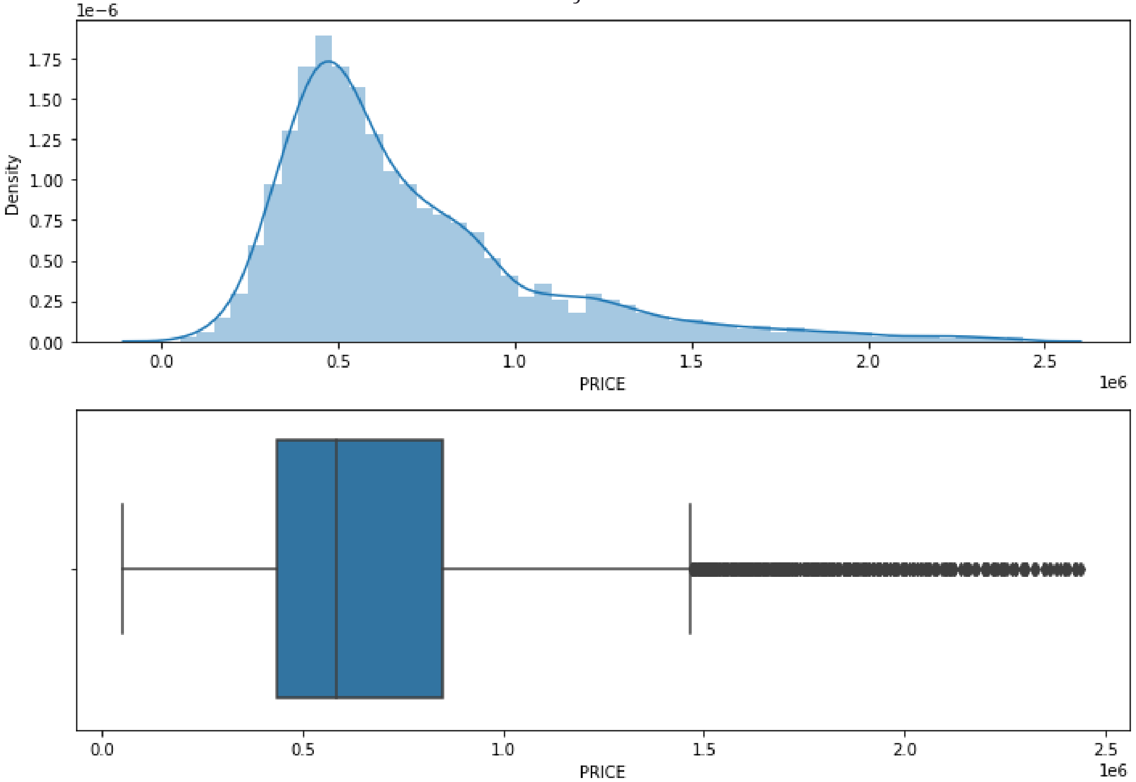

EDA (GitHub)

Área de terreno e Área construída

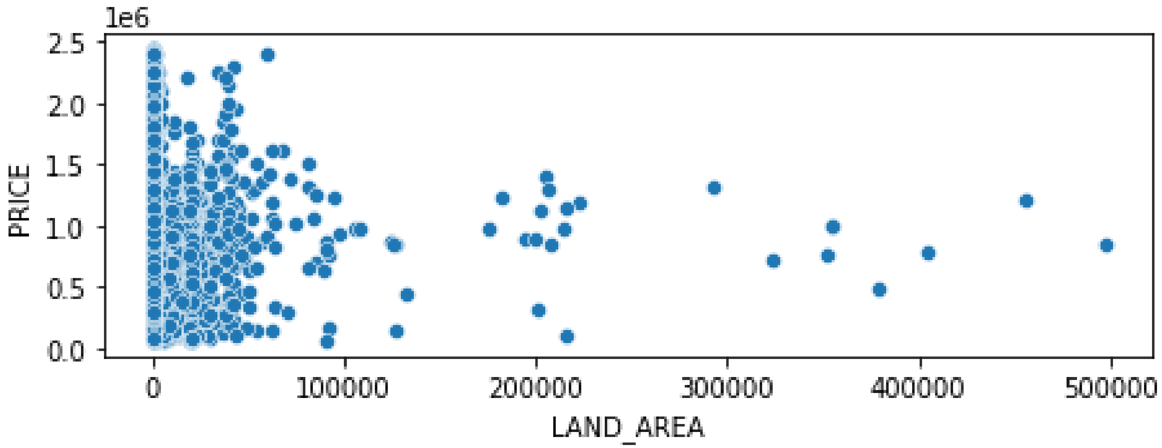

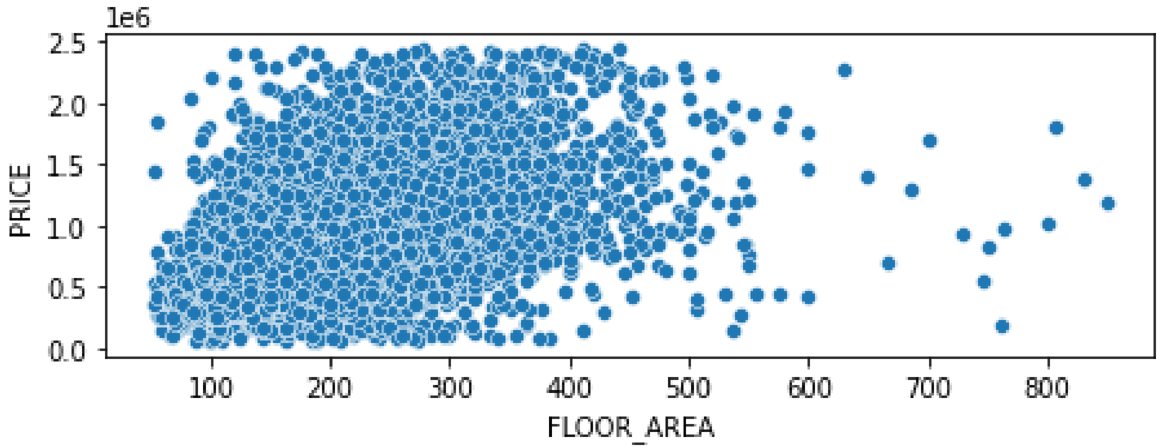

As áreas não apresentam comportamento que pareça ser muito decisivo para a definição de preço.

EDA (GitHub)

Distância para o Centro da cidade, Estação de trem e Escola mais próximos

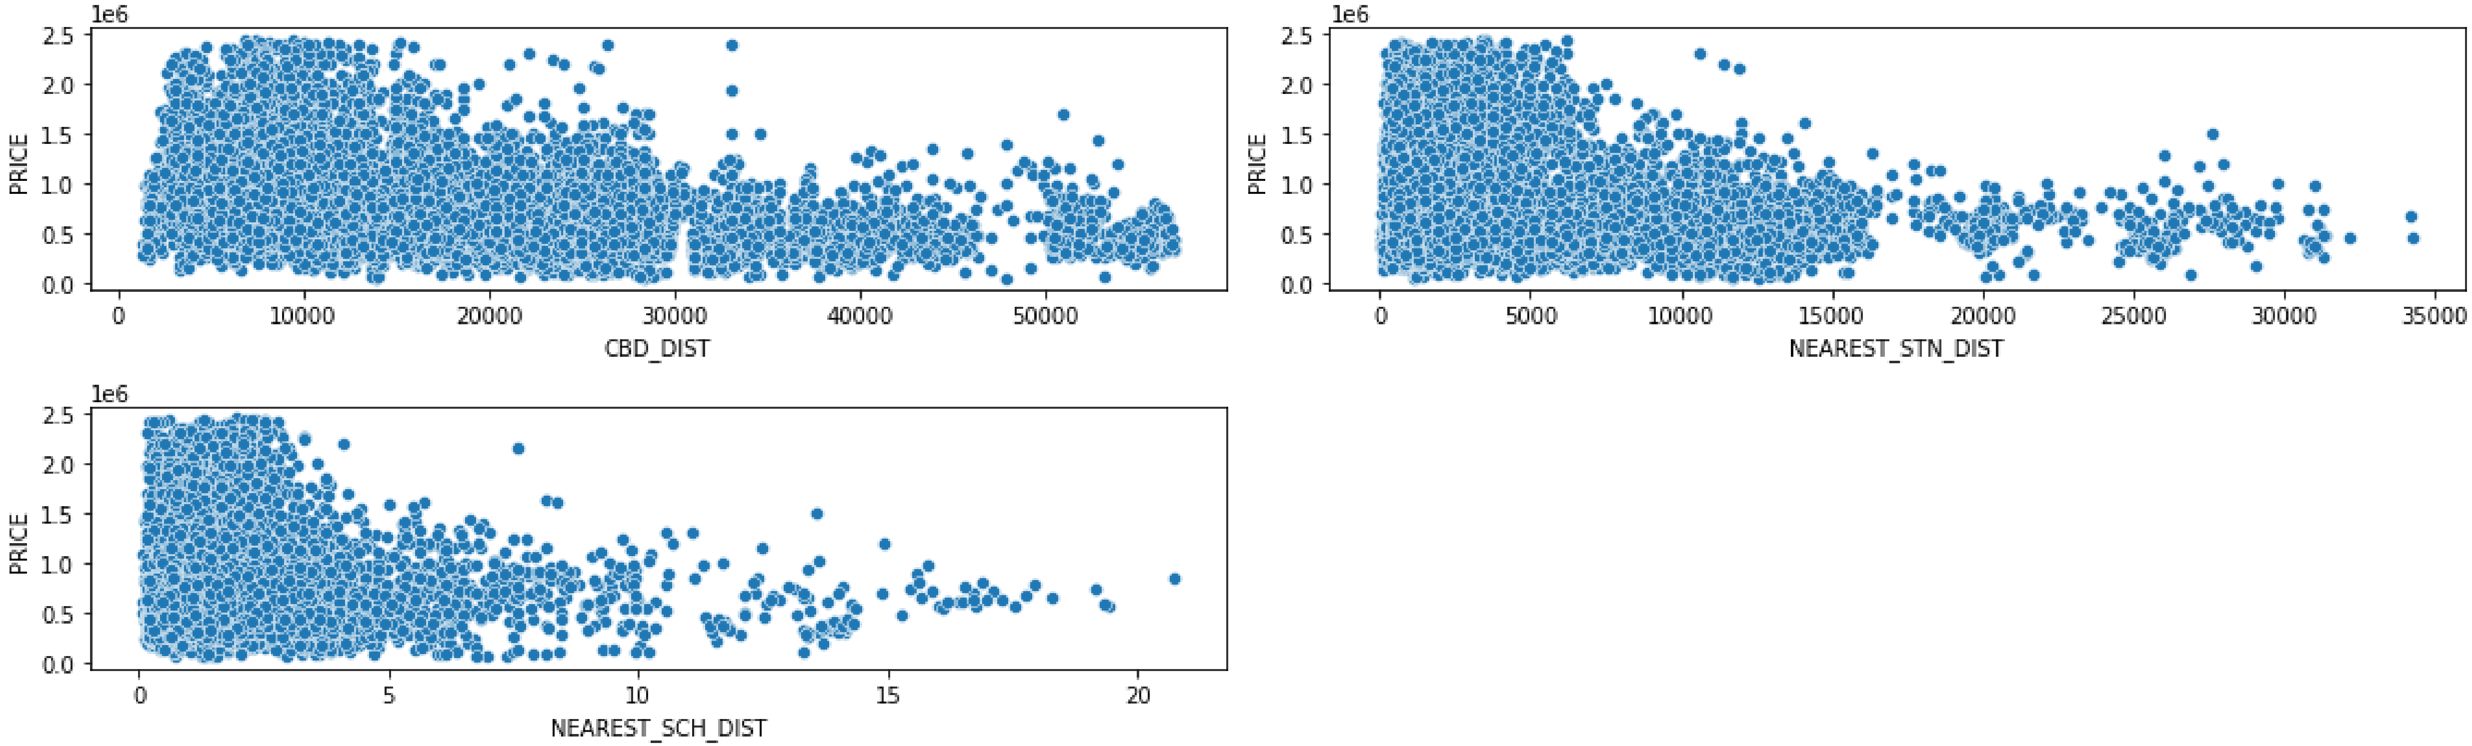

As distâncias mostram uma correlação inversa ao preço das casas, tendendo a serem mais decisivas para o valor.

EDA (GitHub)

Os preços aumentam significativamente após as Olimpíadas de Sidney (2000) e o aumento global do preço das commodities (2003-2004), devido à mineração australiana.

Aumento dos preços por ano

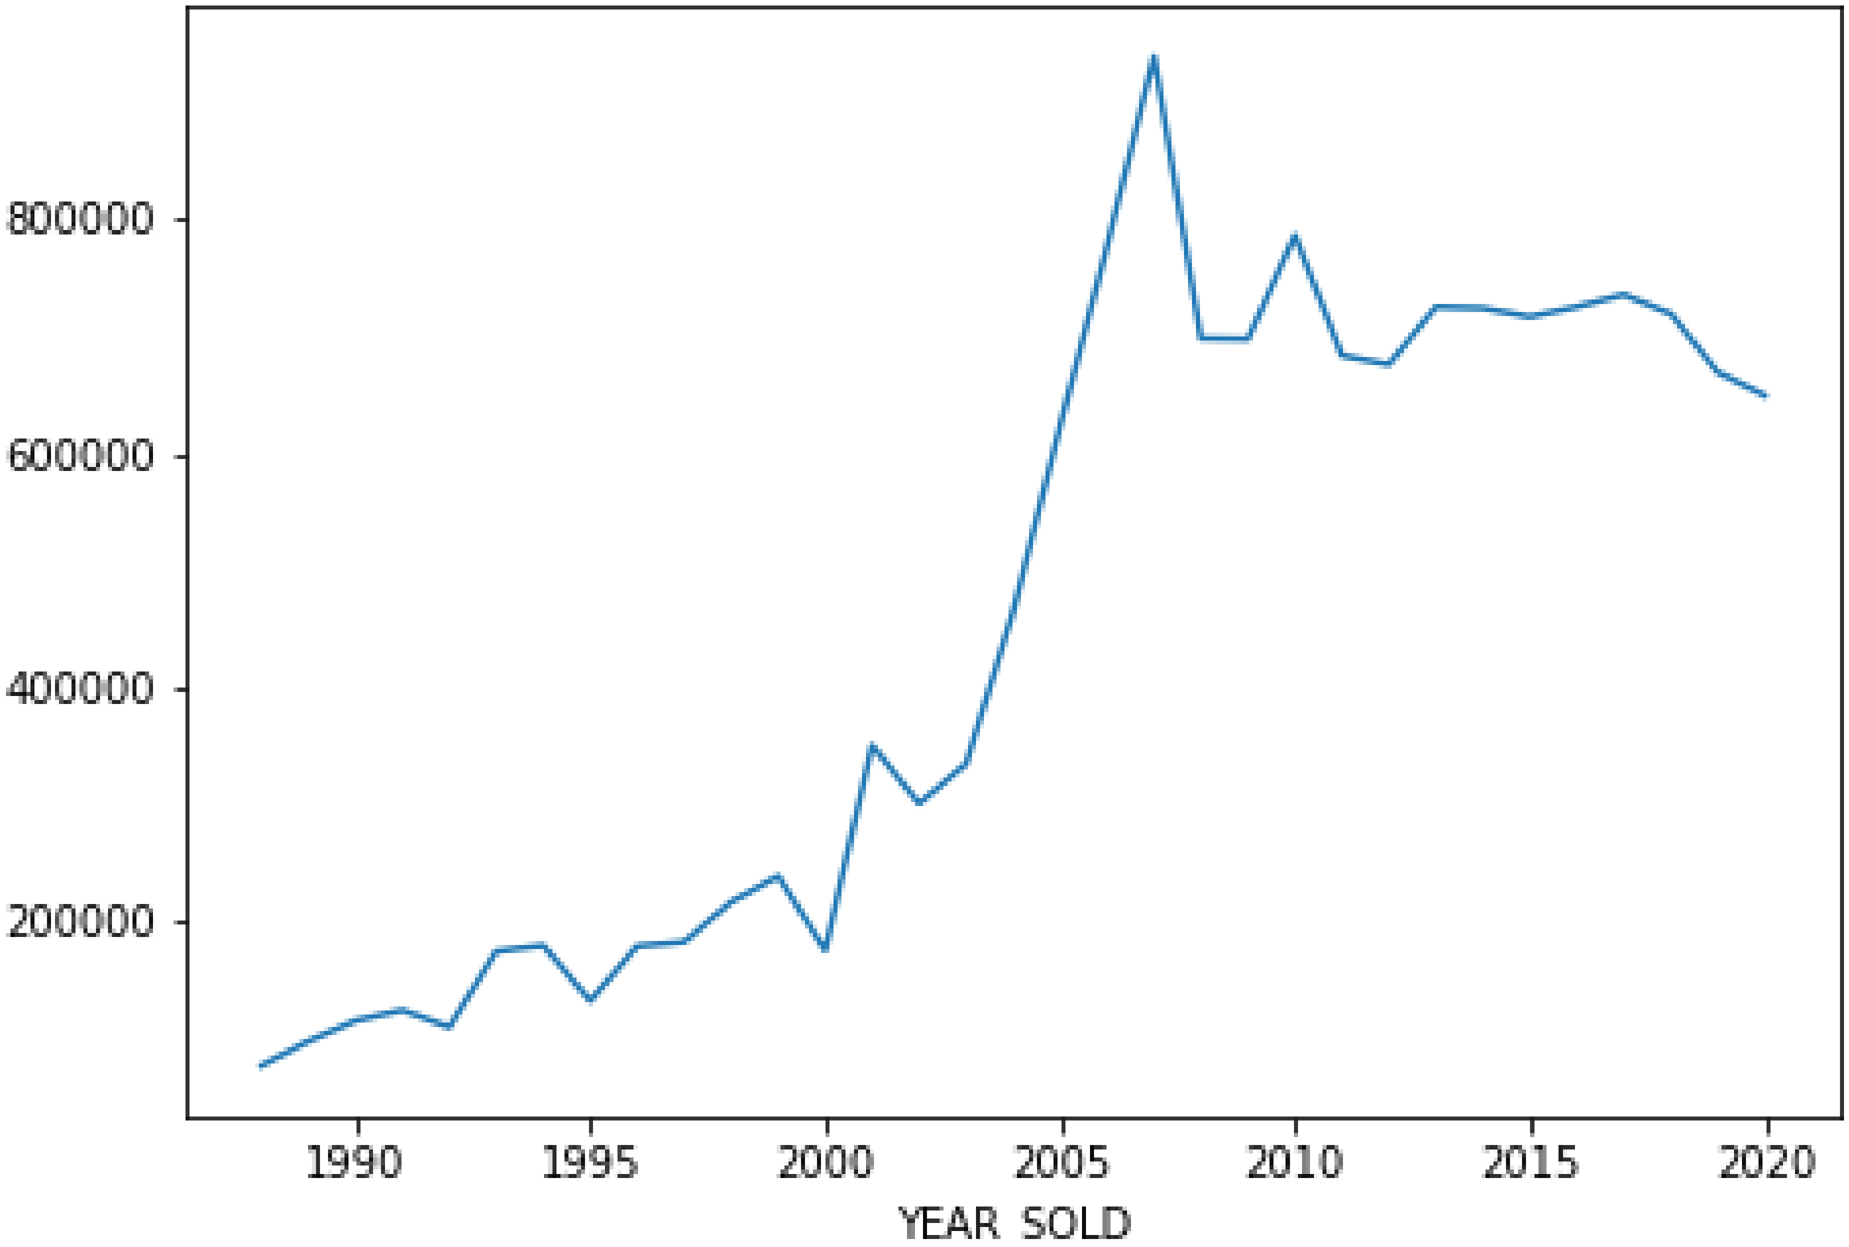

EDA (GitHub)

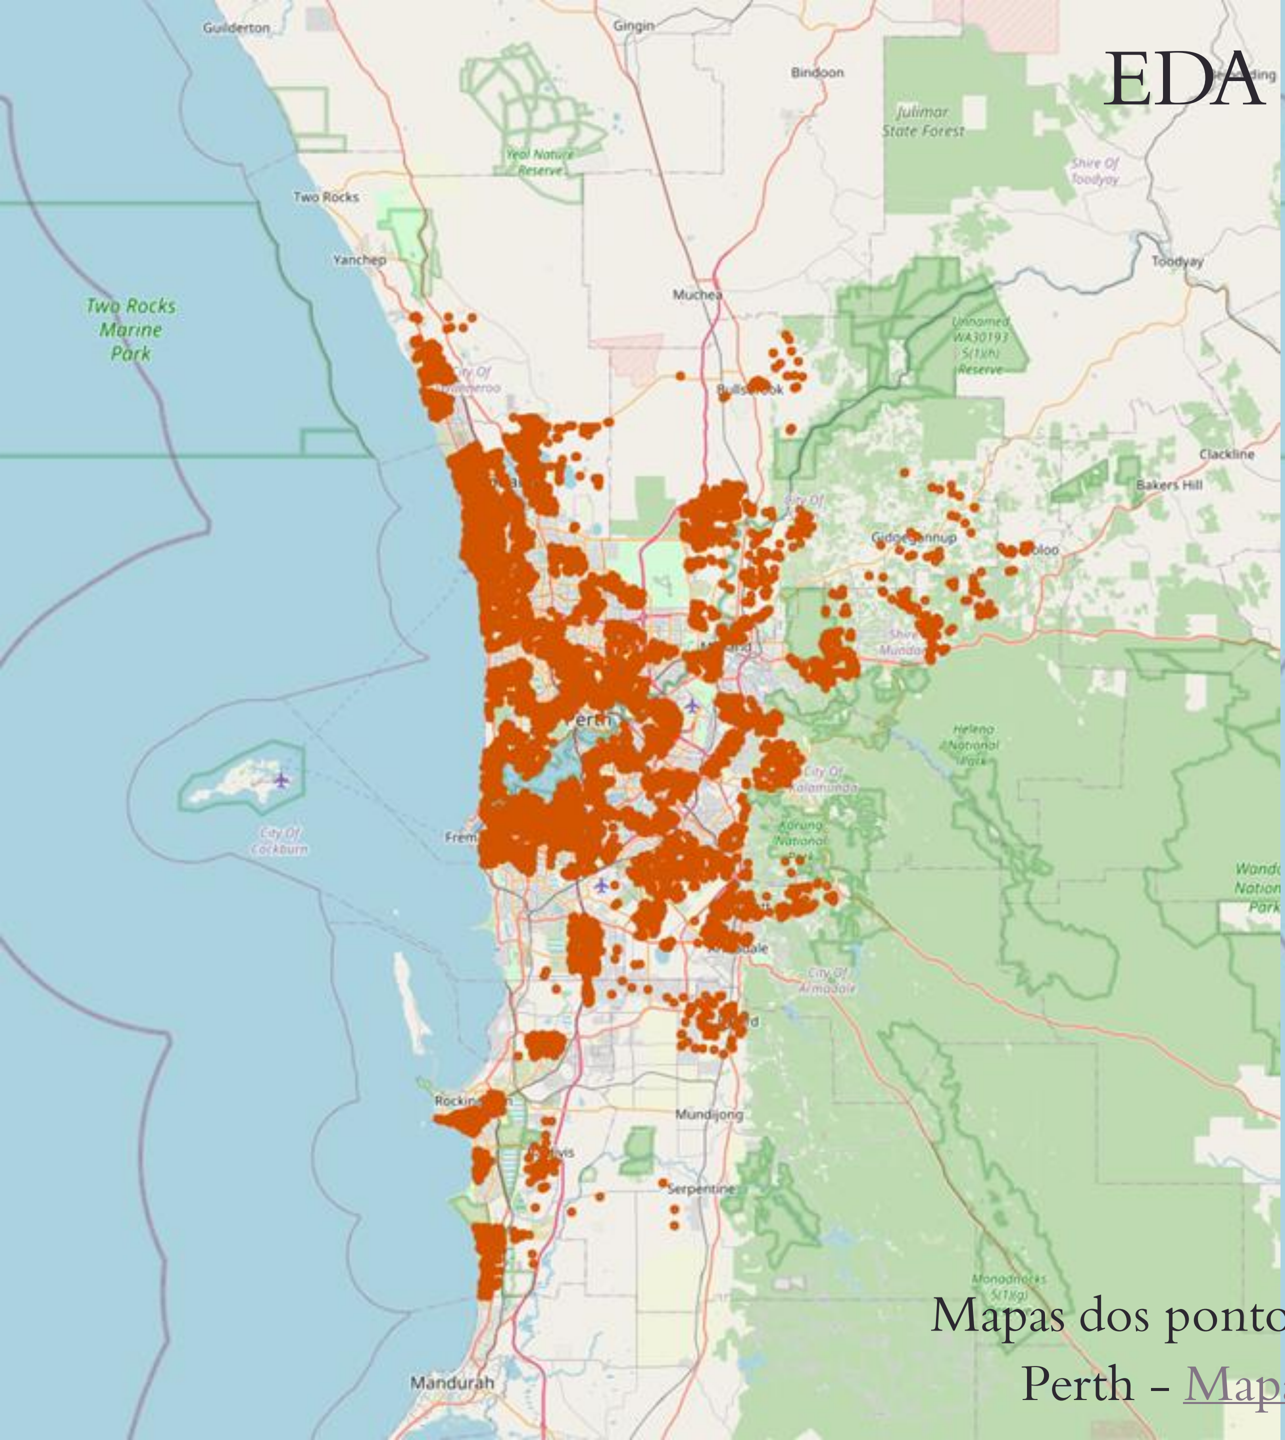

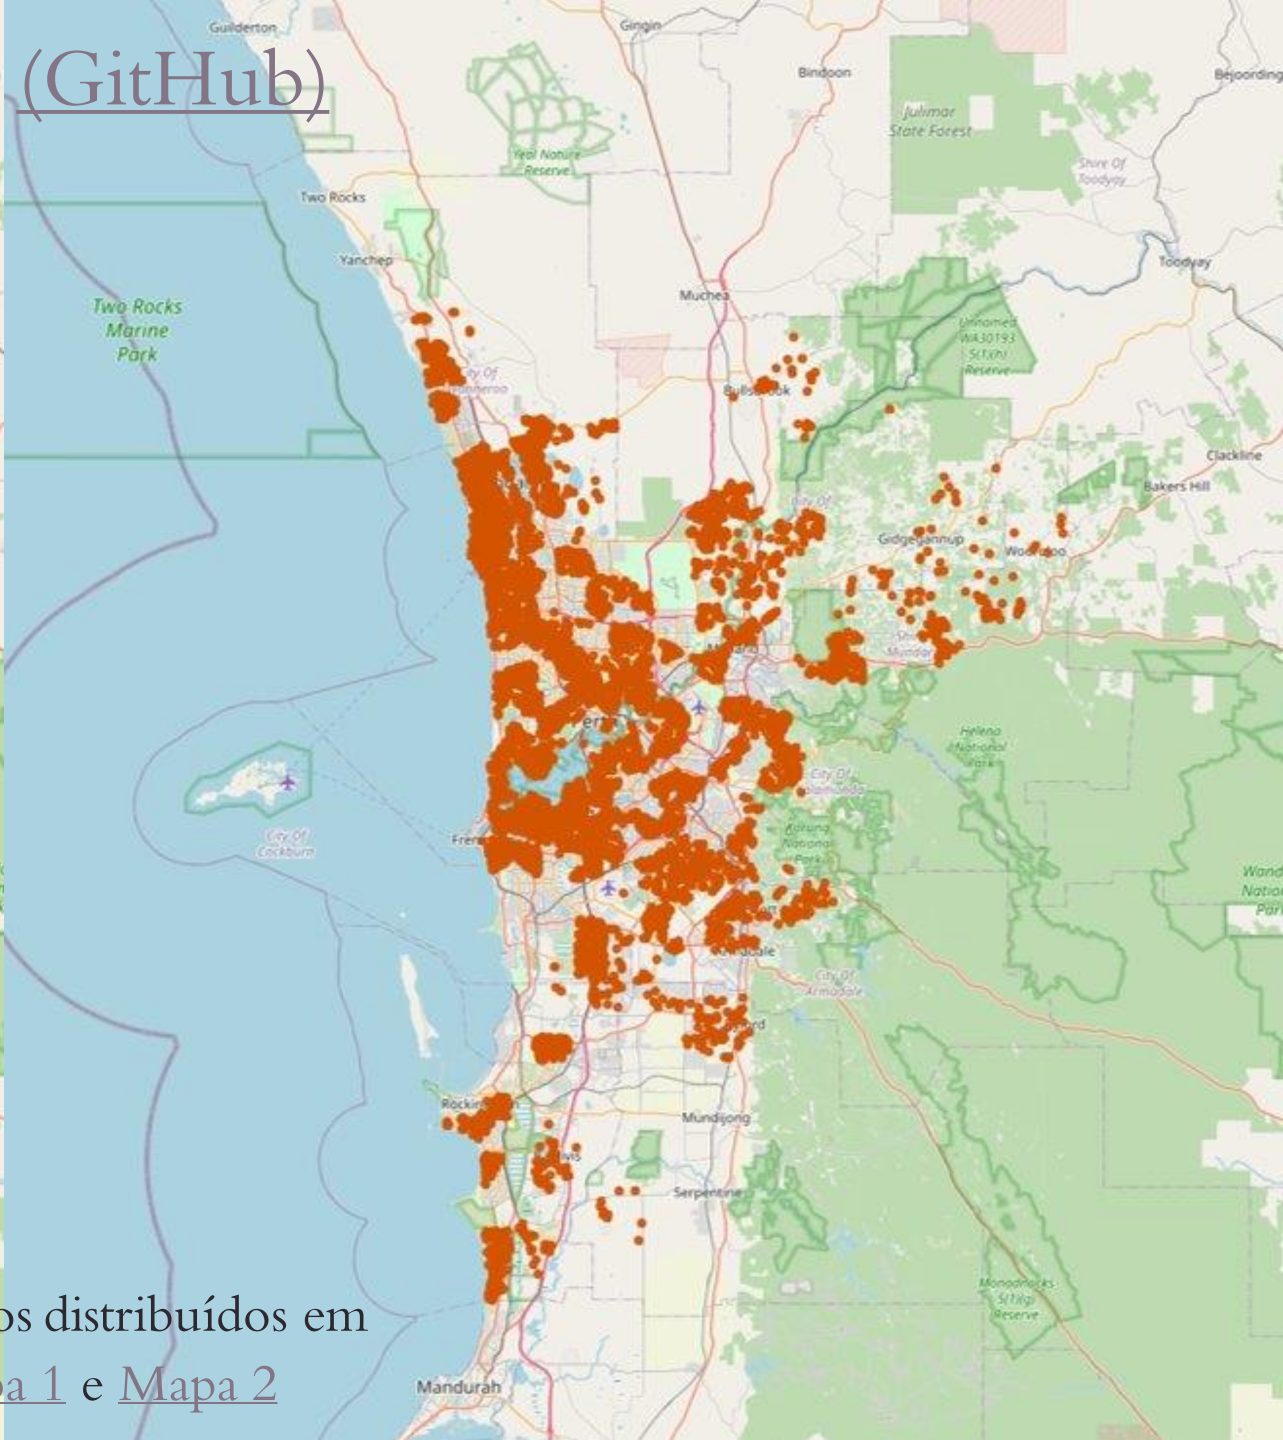

Mapas dos pontos distribuídos em Perth – Mapa 1 e Mapa 2

Feature Engineering [(GitHub)]

Aplicação de log para lidar com distribuição enviesada;

Mudança da coluna SUBURB pela média dos preços de cada distrito;

Retirada dos demais dados categóricos.

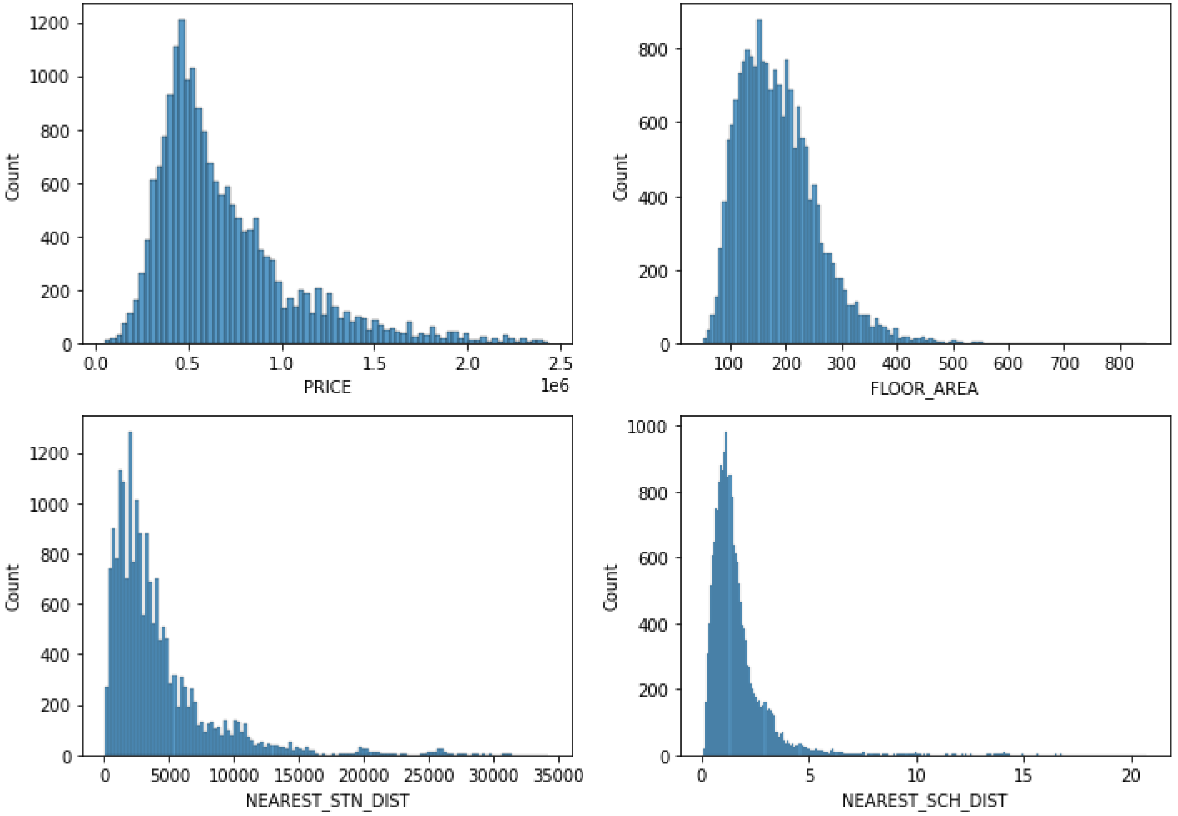

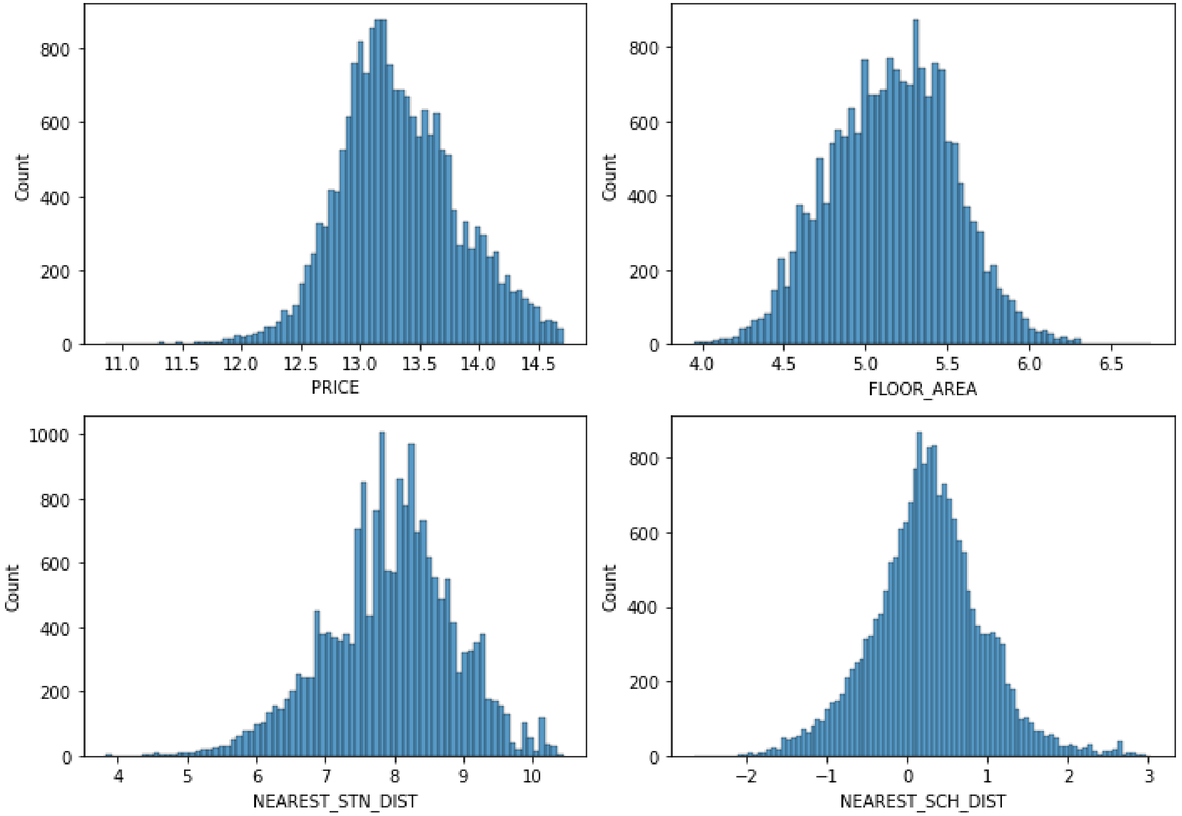

Machine Learnings – Ensemble Learnings

Bagging - aprende os *weak learners* de maneira independente uns dos outros, e os combina seguindo um processo médio determinístico/preditivo;

Boosting - aprende os *weak learners* sequencialmente, adaptando-se e os combinando com uma estratégia determinística/preditiva;

Stacking - aprende *weak learners* em paralelo e os combina num metamodelo para produzir uma previsão baseada nas previsões dos diferentes weak learners.

Stacking (GitHub)

FS – k=3

```
['SUBURB', 'FLOOR_AREA', 'NEAREST_SCH_RANK']
```

Modelos aplicados:

- Redes Neurais;
- *SVM;*
- Árvore de decisão;
- *KNN;*
- Regressão Linear.

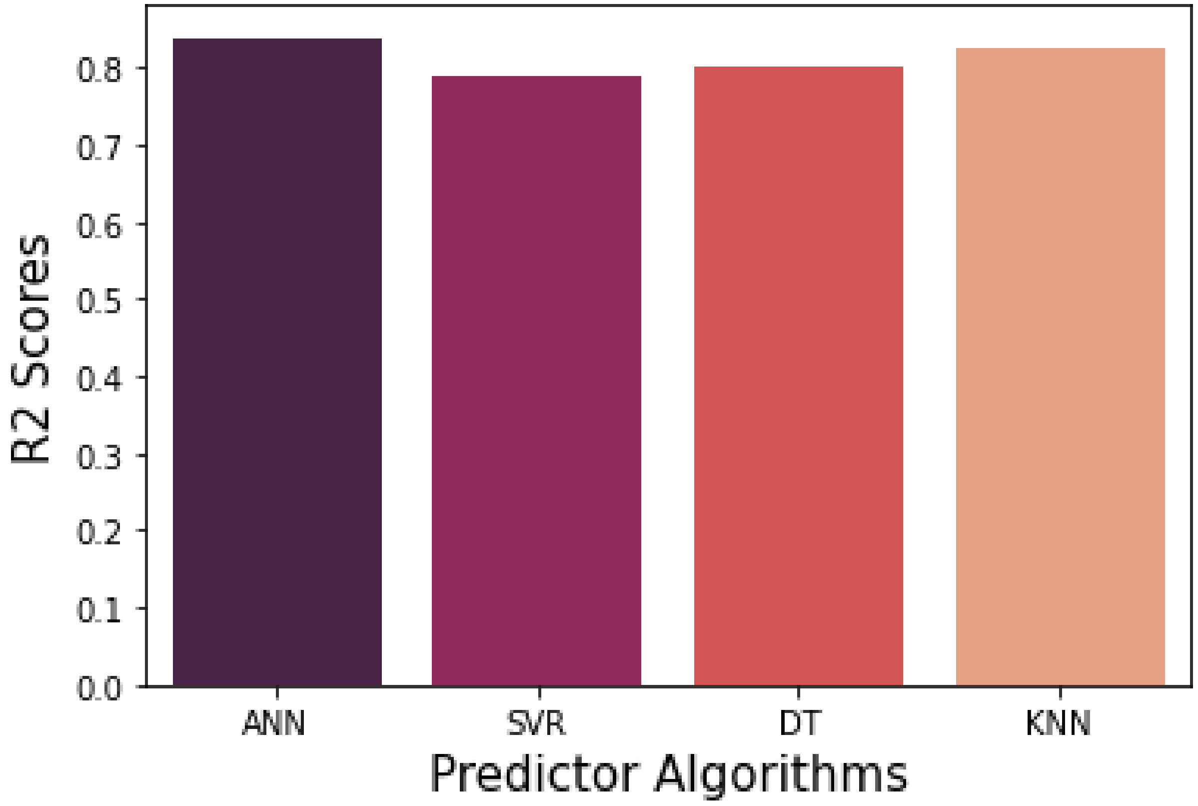

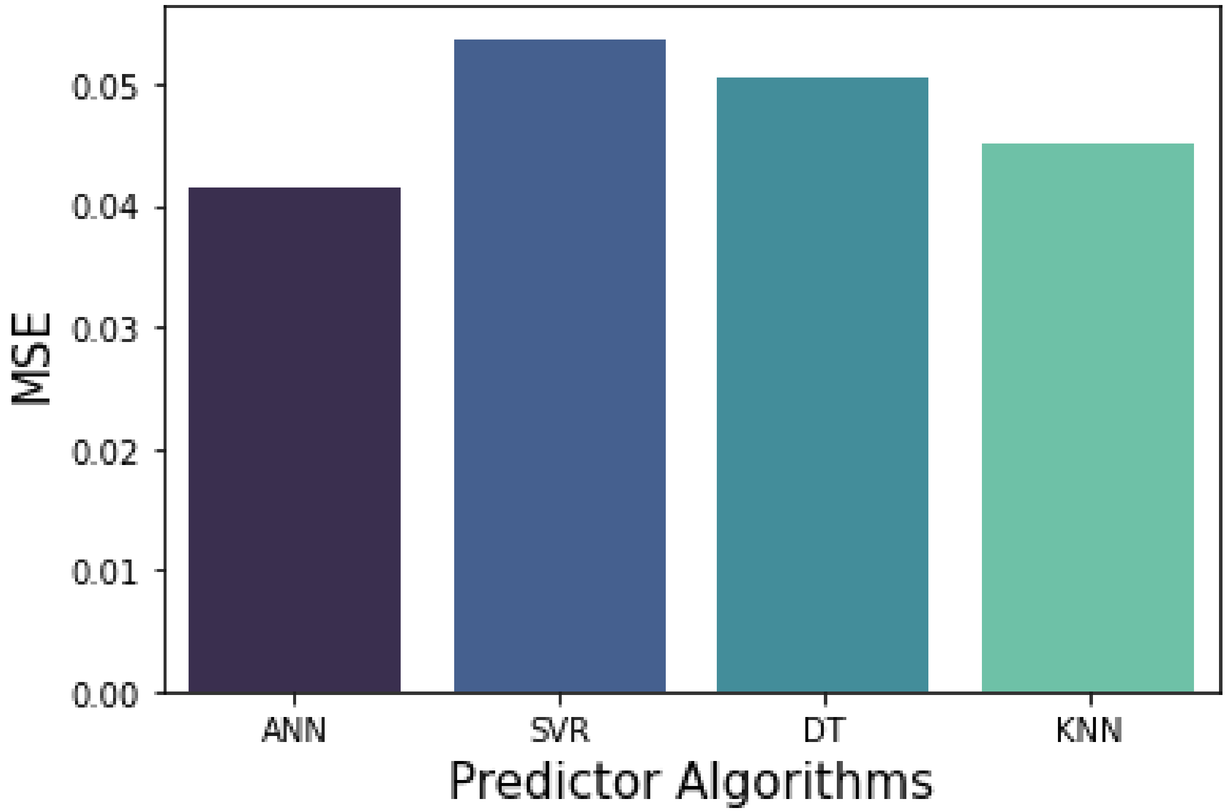

Stacking (GitHub)

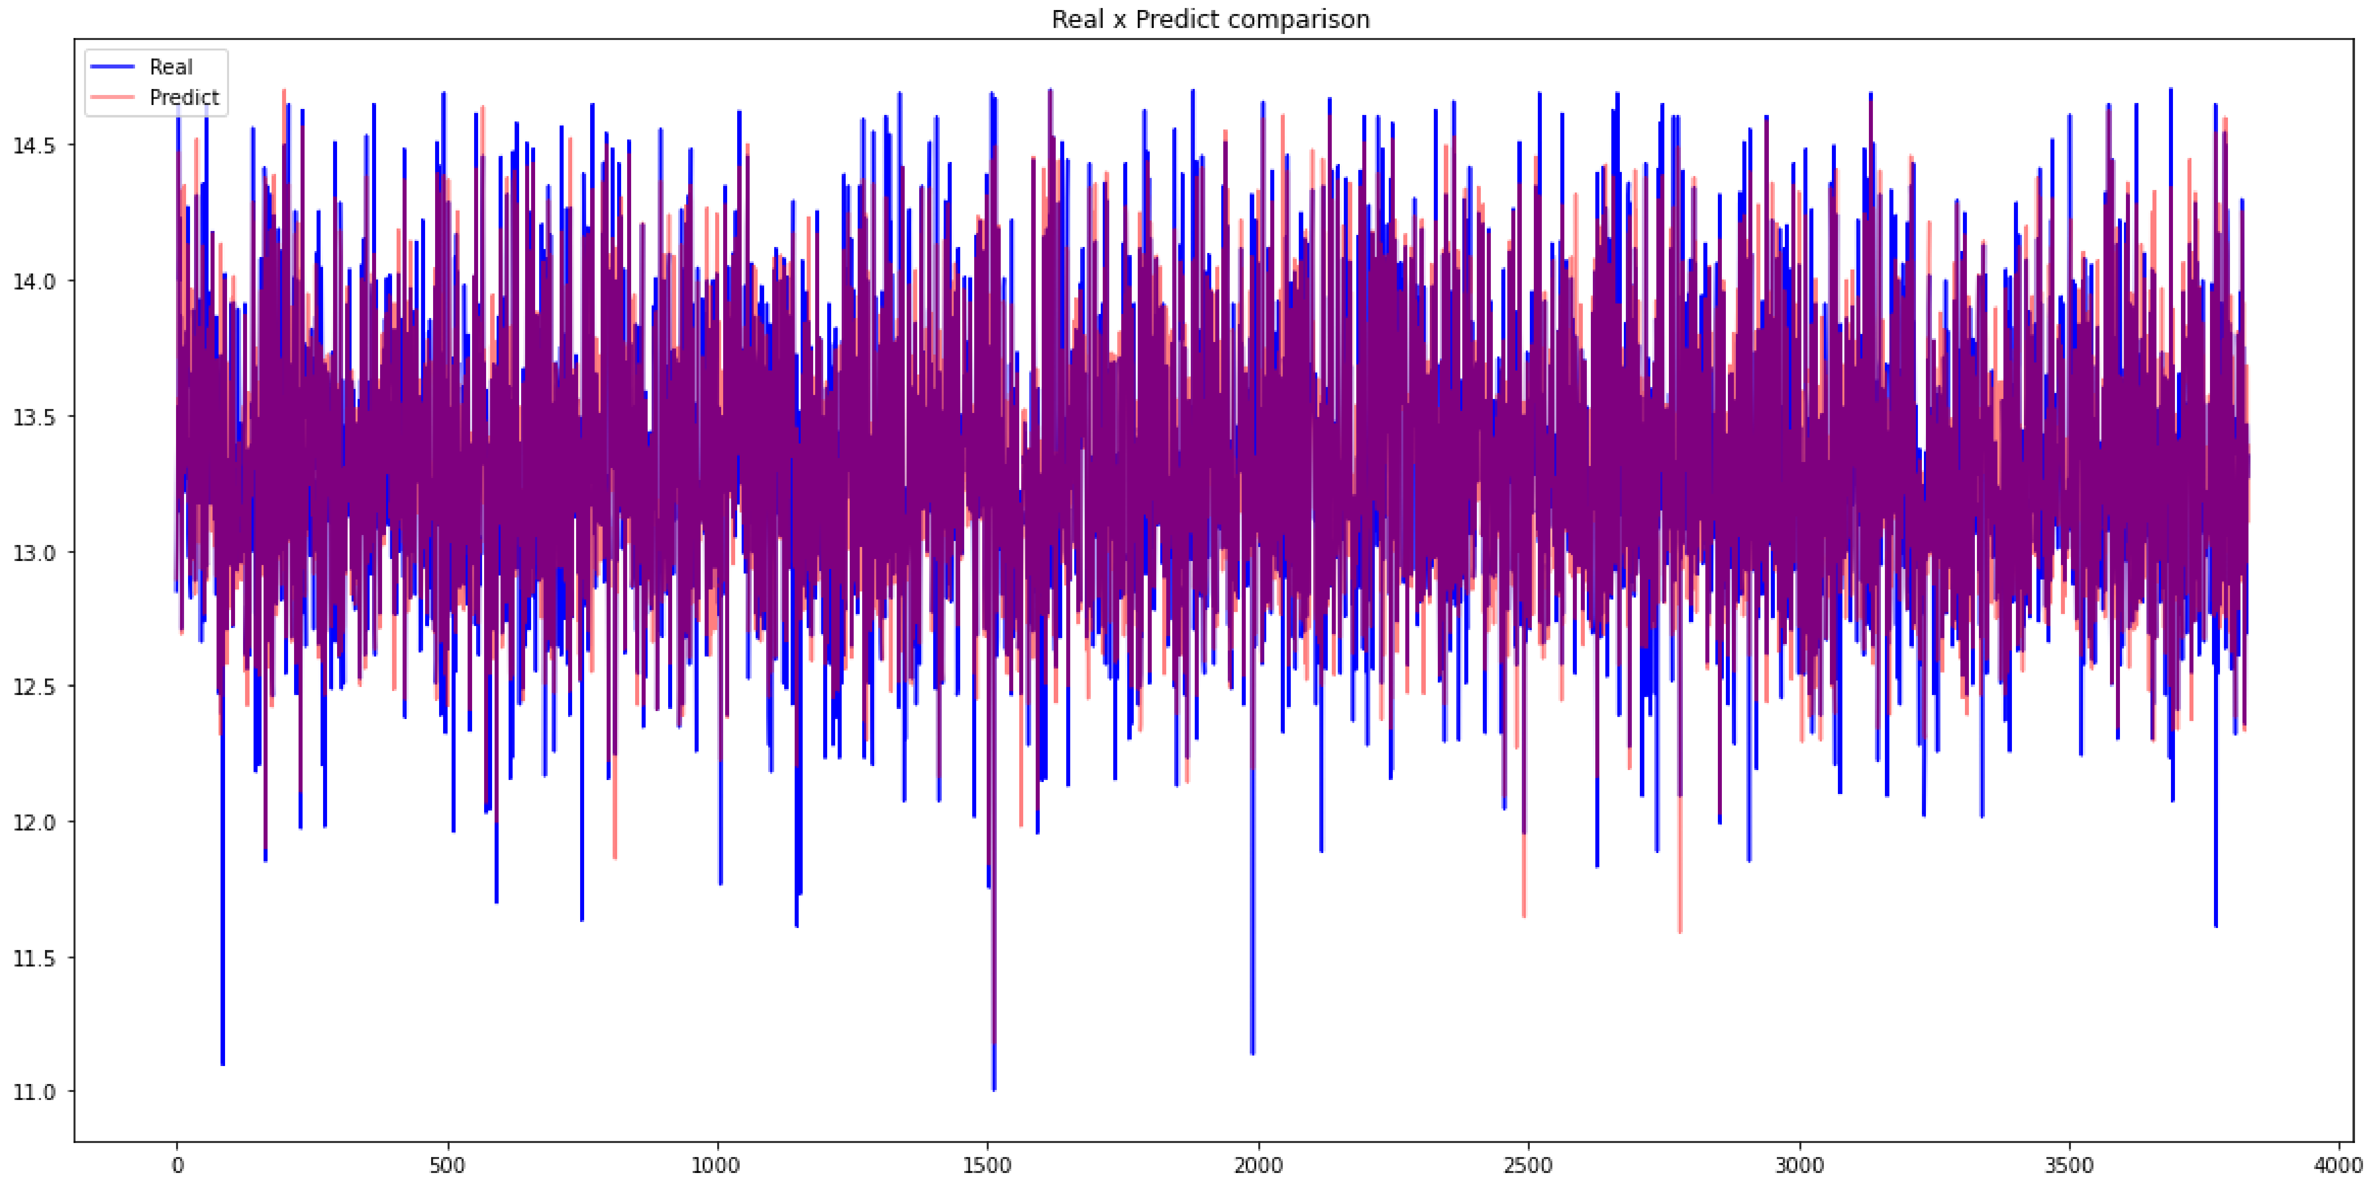

BAGGING (GITHUB)

Modelo aplicado – Random Forest

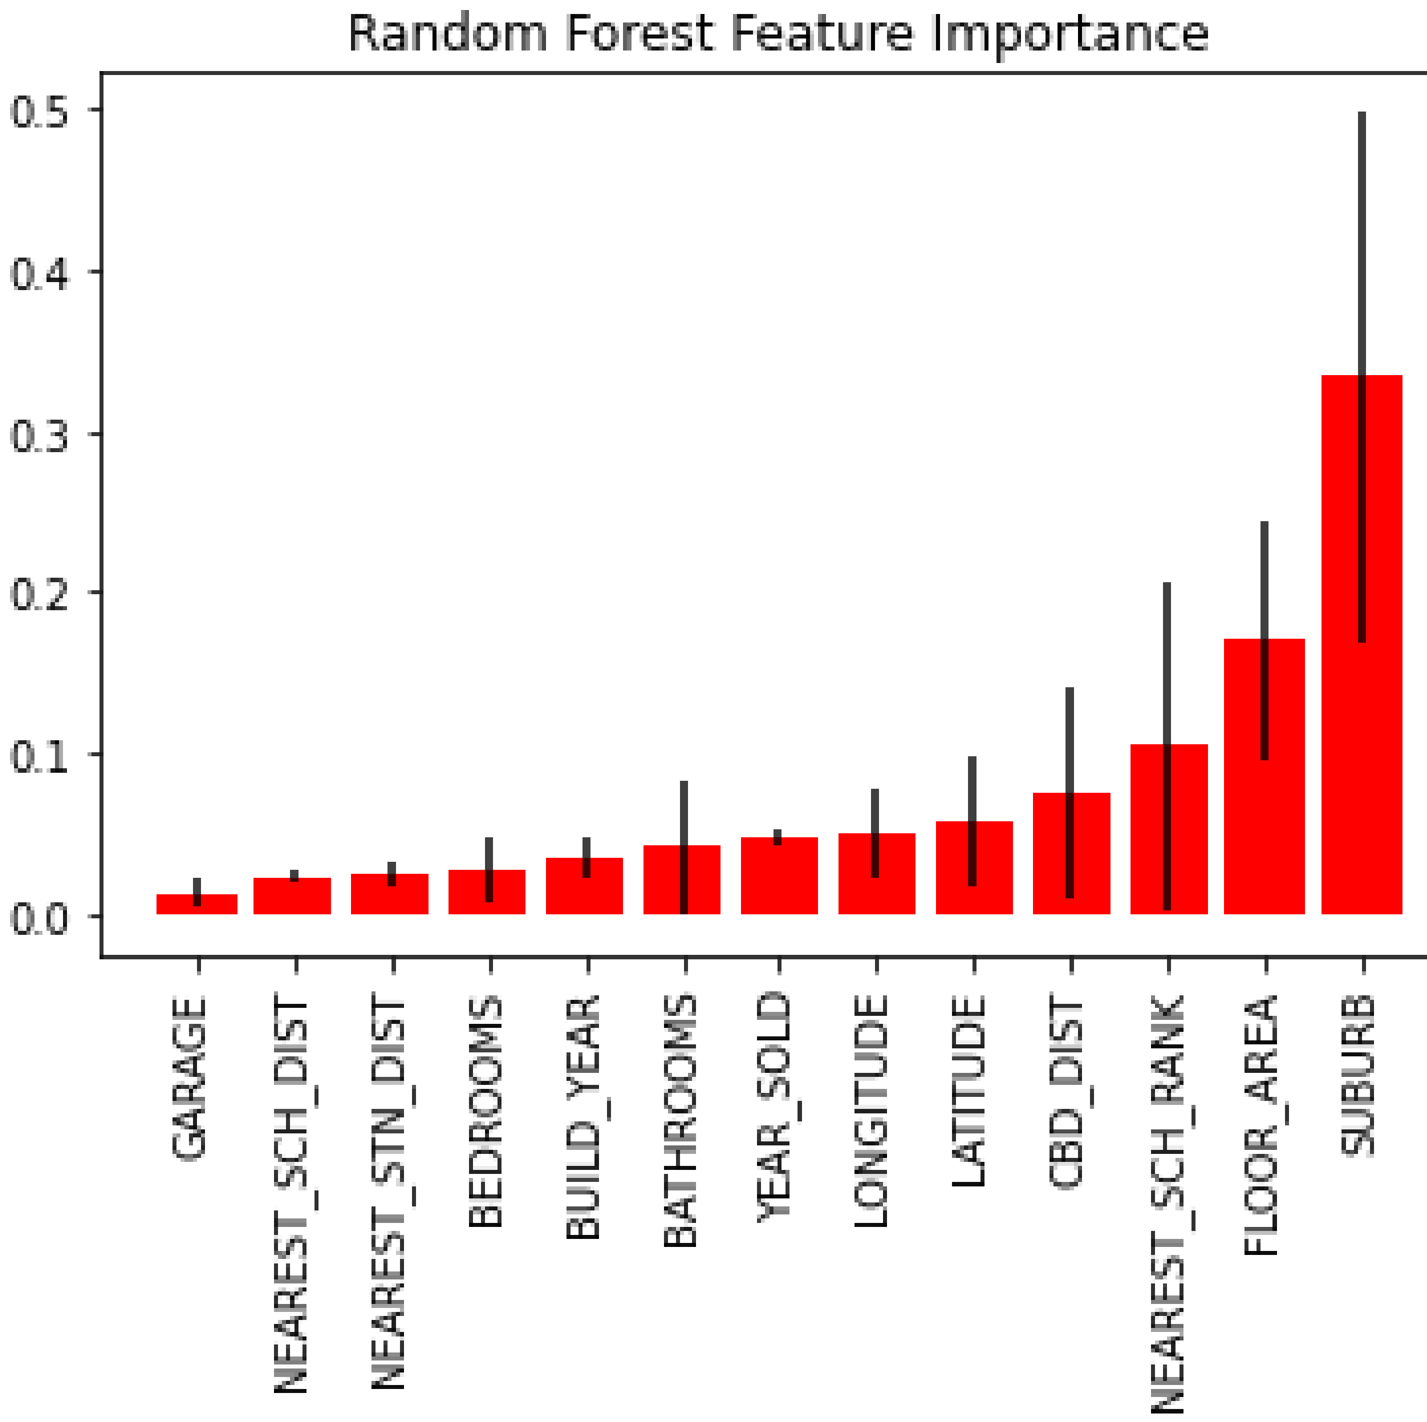

Bagging (GitHub)

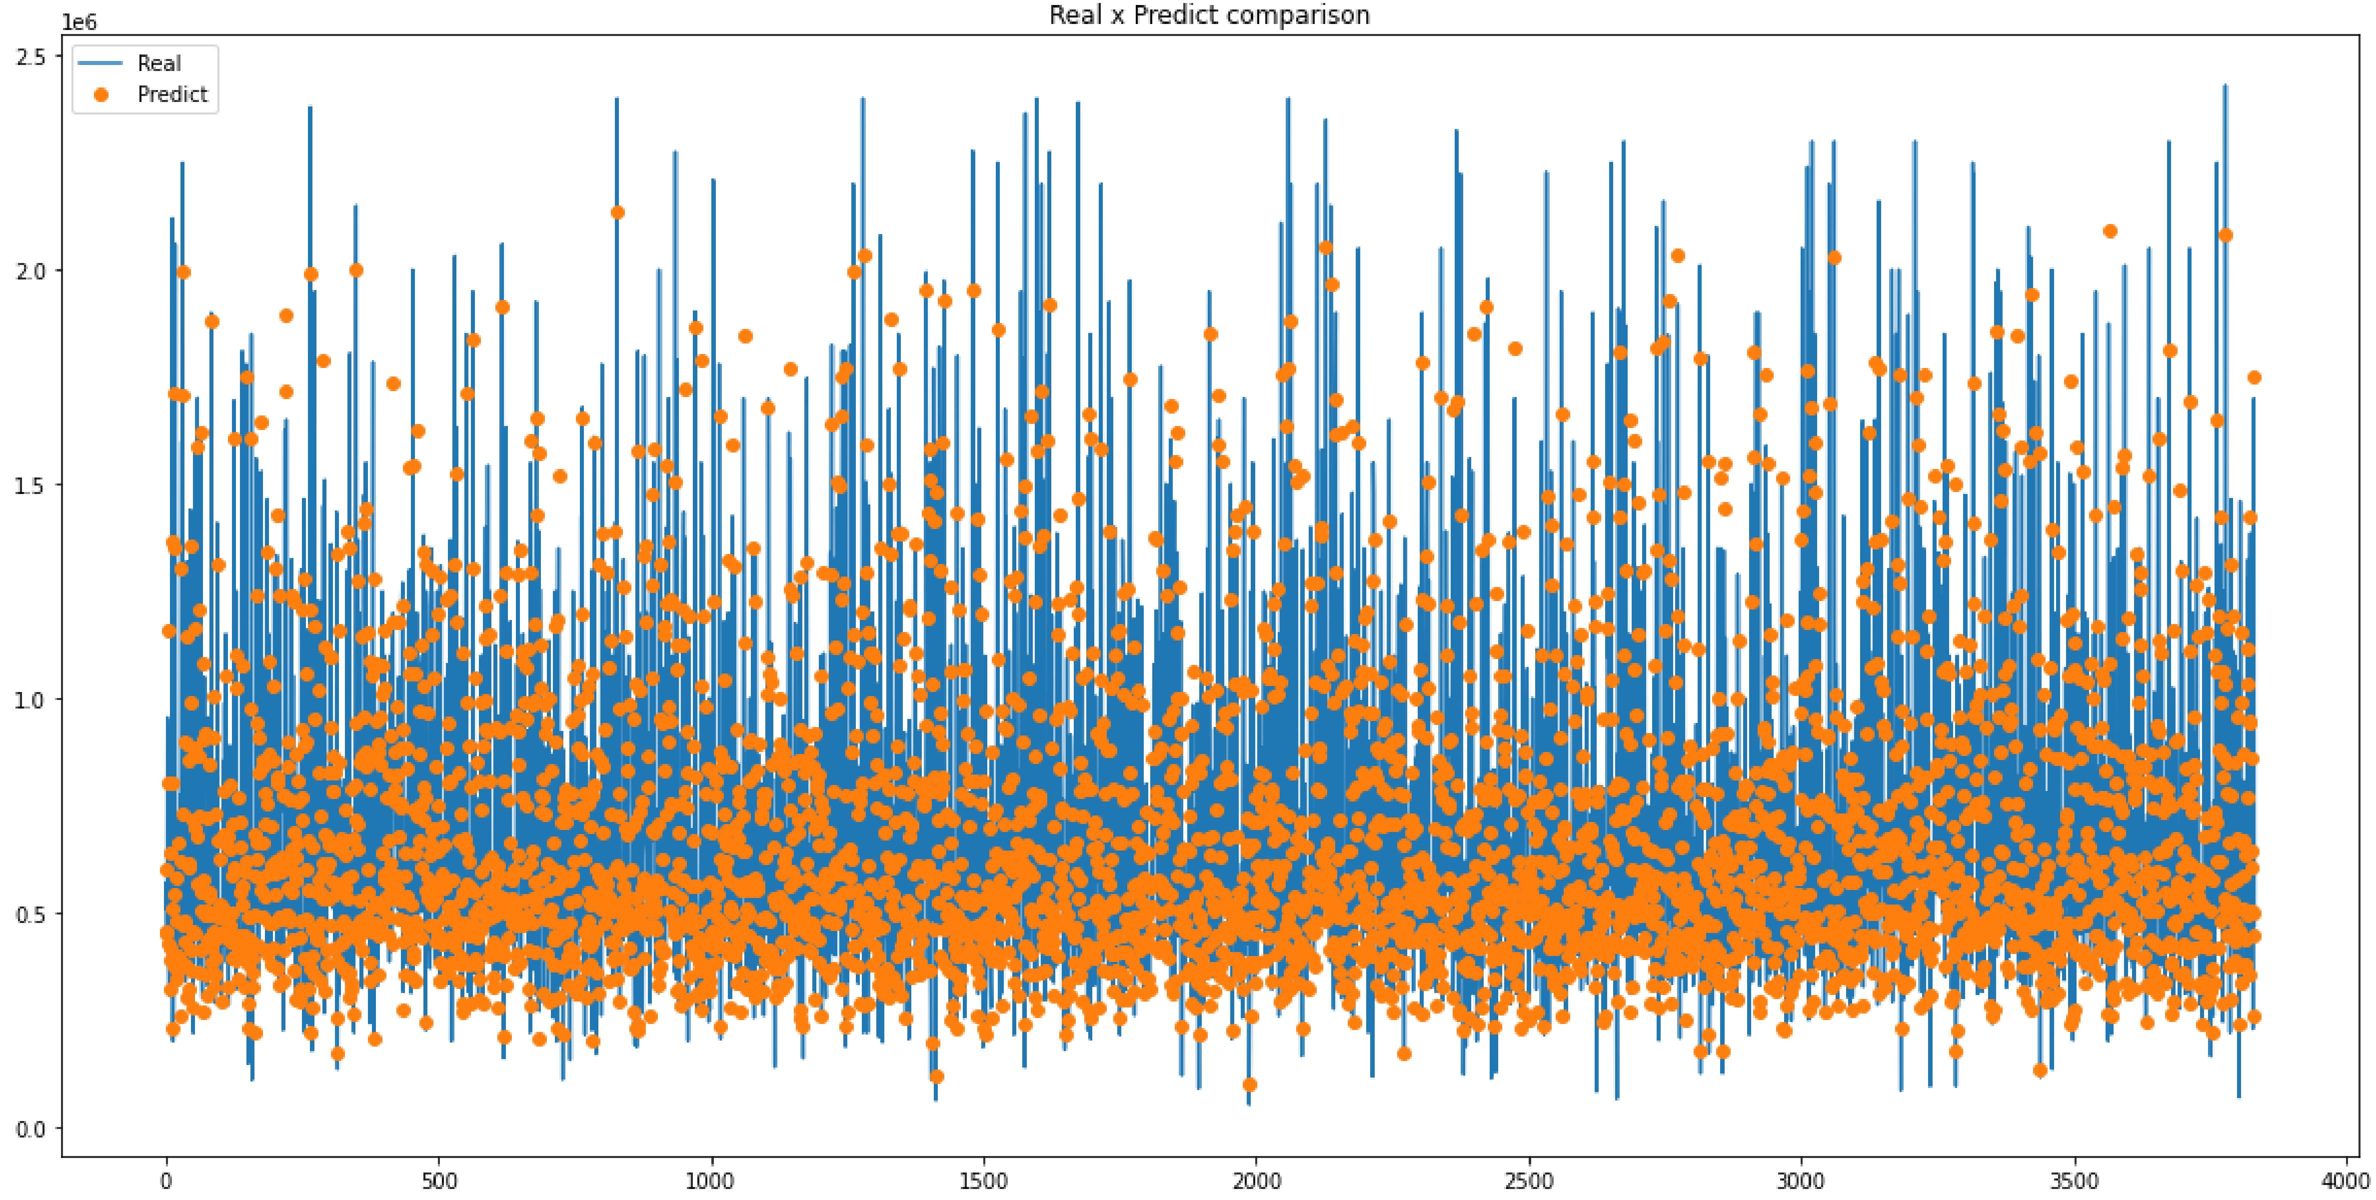

BOOSTING (GITHUB)

Modelo aplicado – Extreme Gradient Boosting

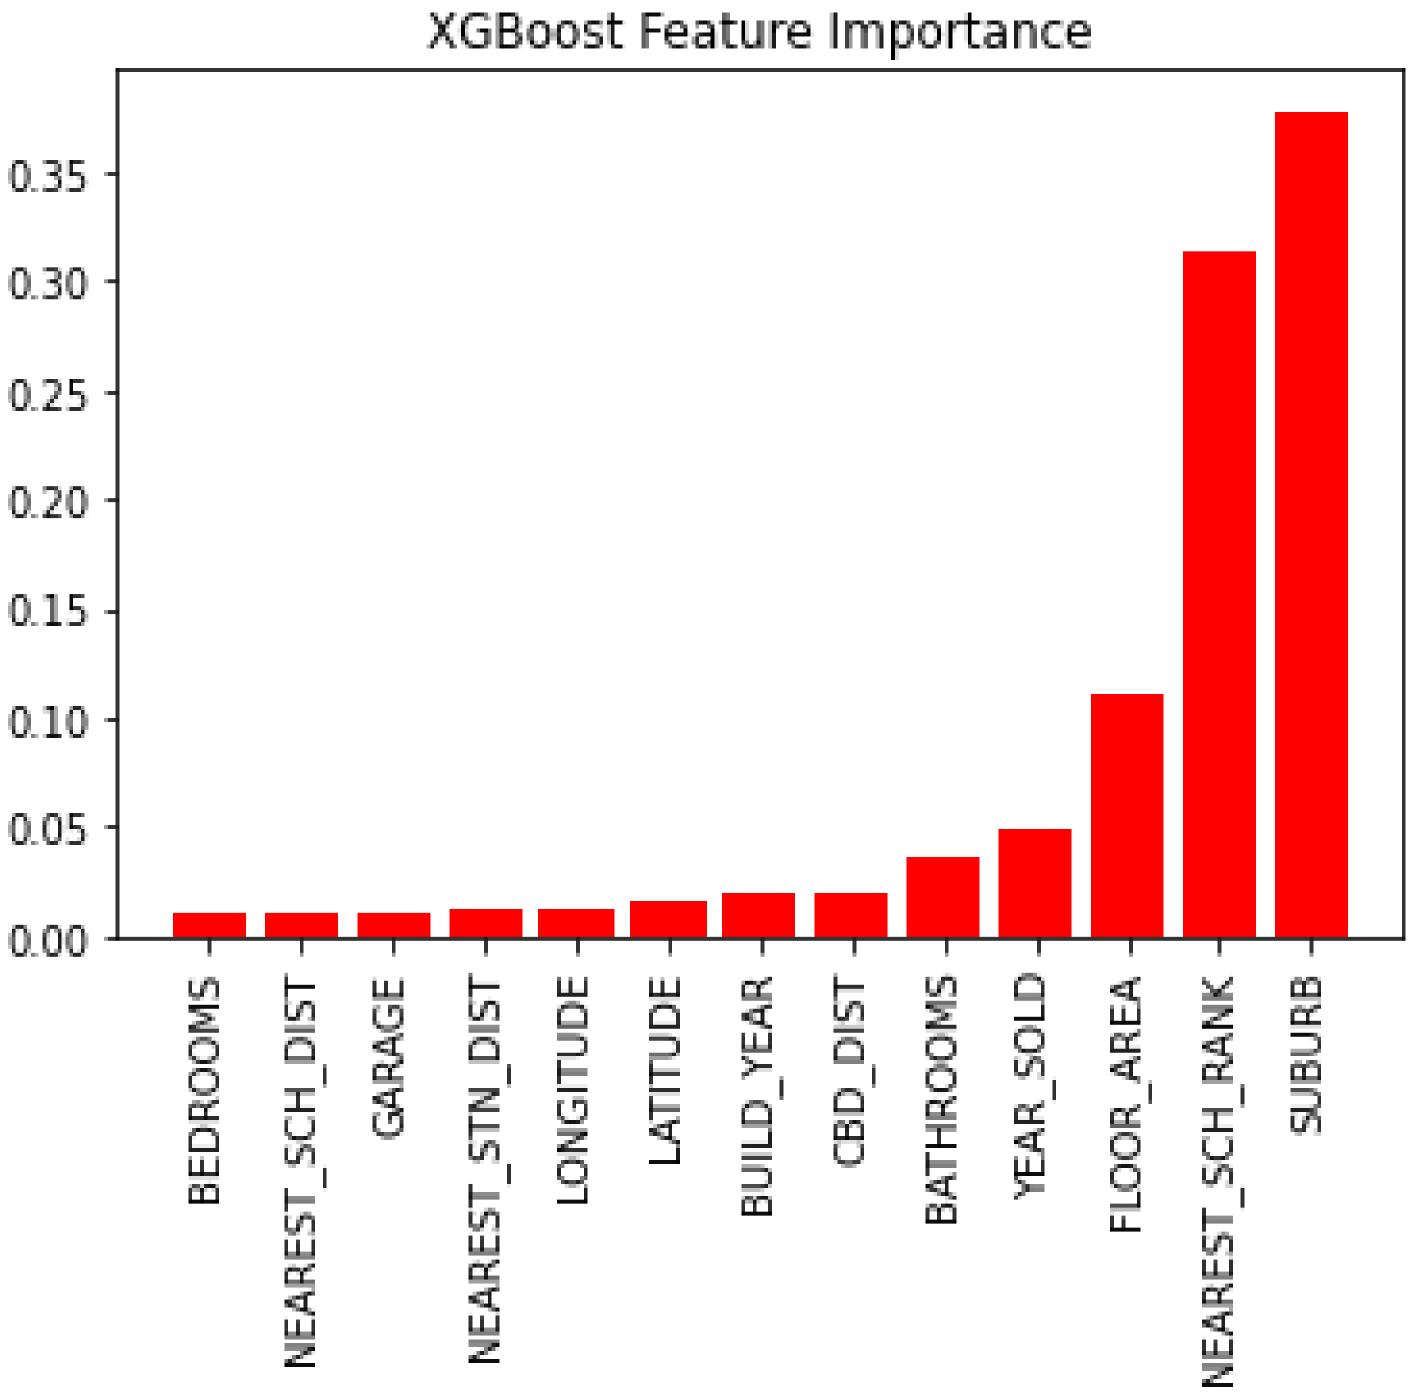

Boosting (GitHub)

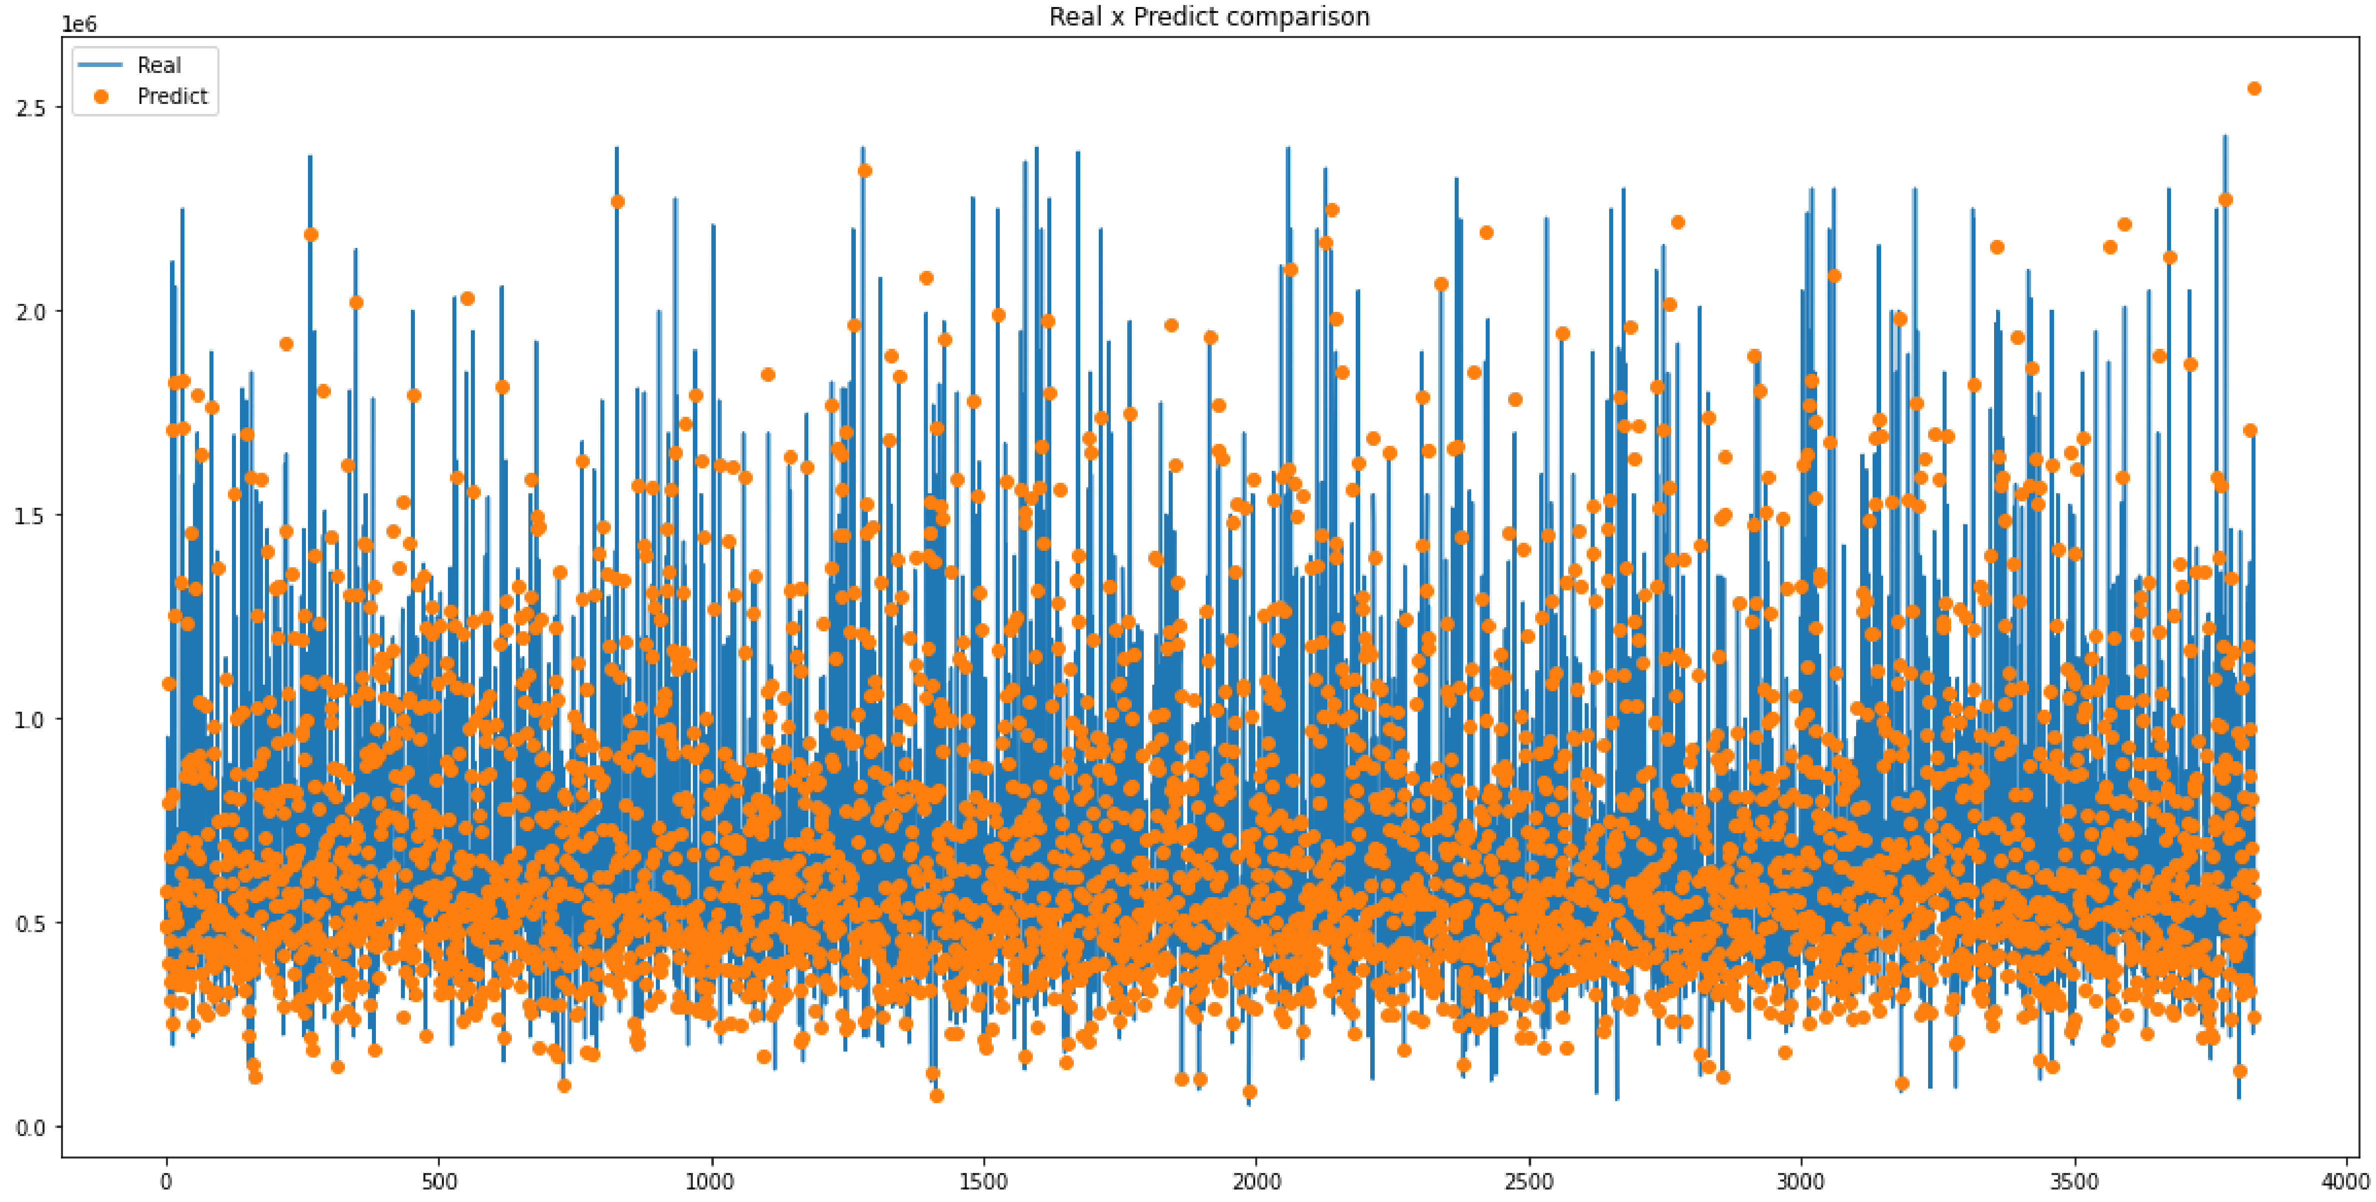

R² e MSE dos Ensemble Learnings

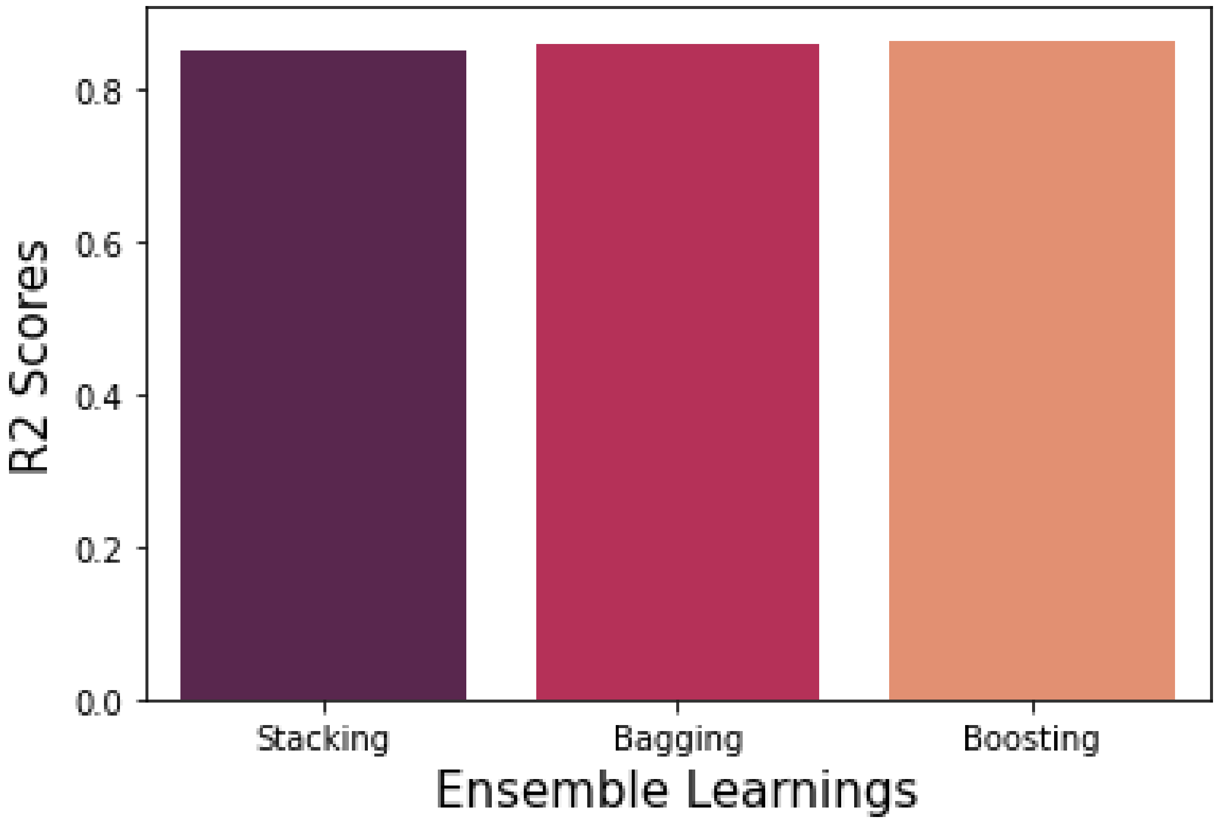

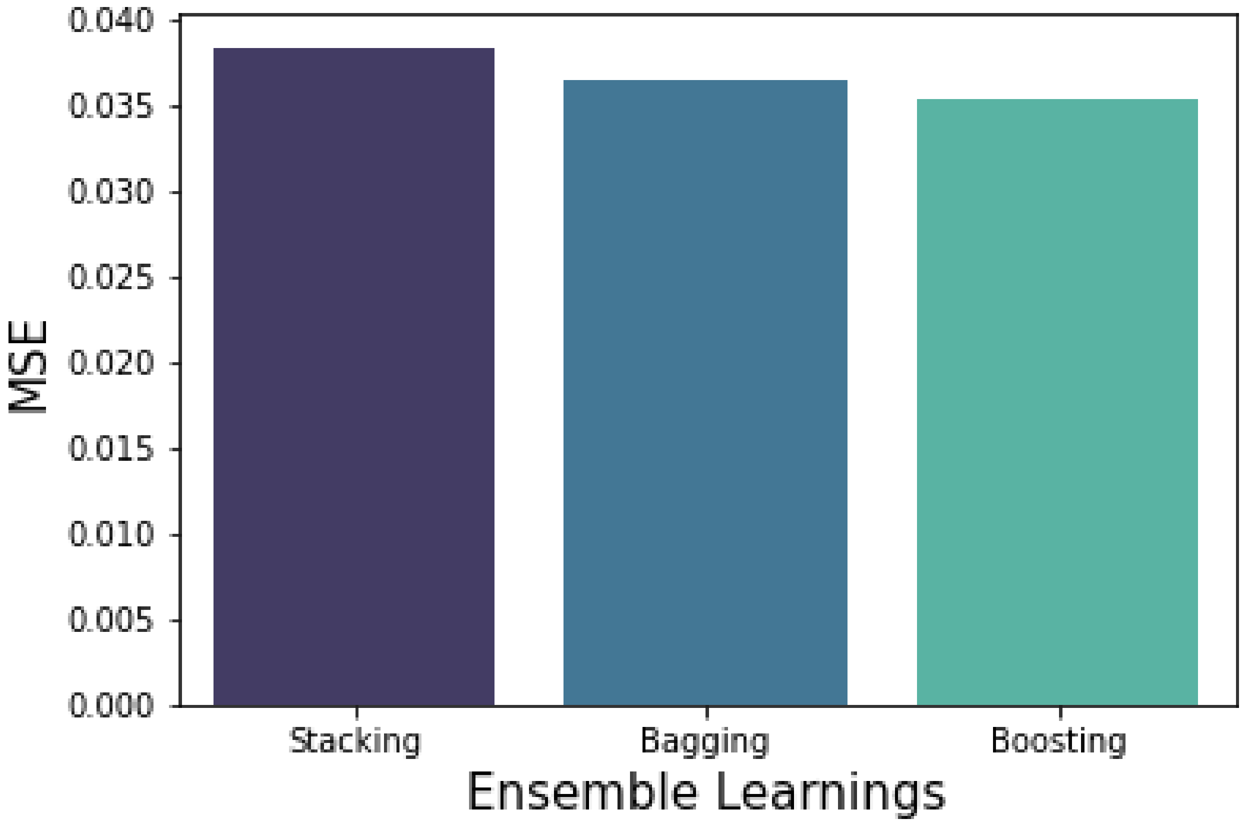

	R2	MSE
Stacking	0.850600	0.038409
Bagging	0.859343	0.036571
Boosting	0.864239	0.035298

Deploy (App)

Streamlit – framework de código aberto, criado para colocar em funcionamento os projetos de Machine Learning, sem a necessidade de ferramentas de front-end ou de deploy de aplicações.

Streamlit

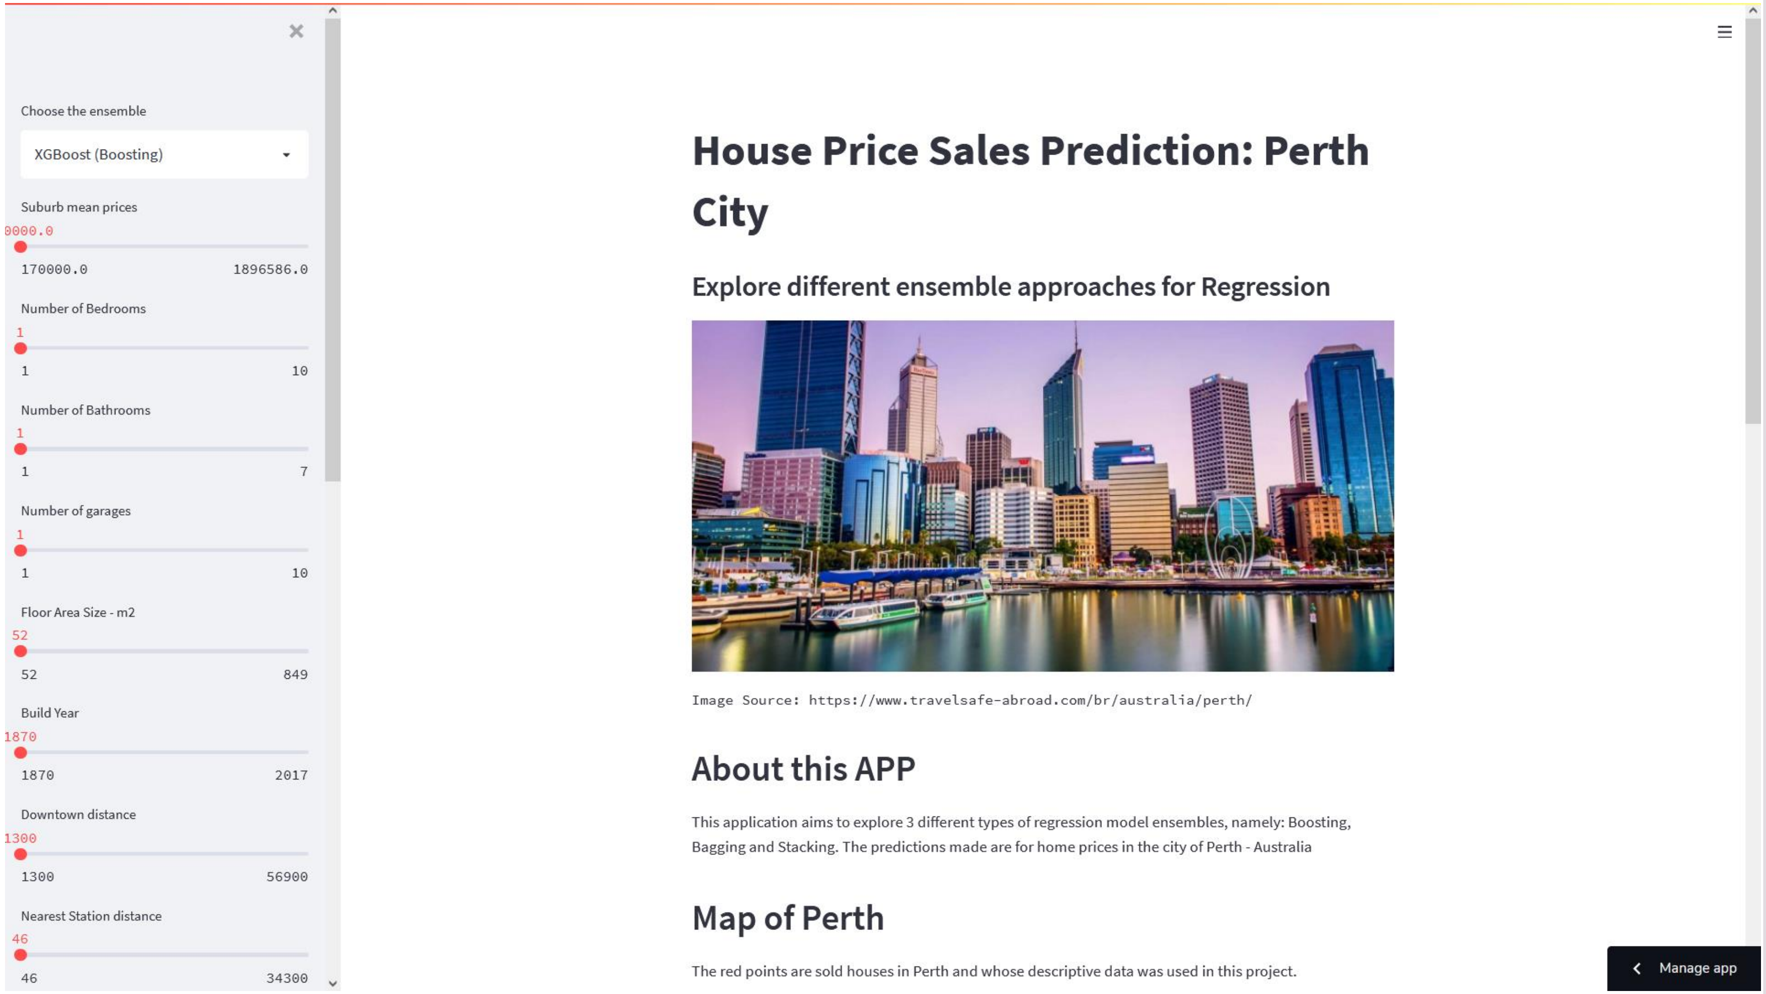

MUITO OBRIGADO!

github.com/alexr06 - linkedin.com/in/alexrodriguesdeoliveira

github.com/leilaff89 - linkedin.com/in/leila-fabiola-ferreira-31675163